

PENERAPAN LONG SHORT TERM MEMORY PADA DATA TIME SERIES UNTUK MEMPREDIKSI PENJUALAN PRODUK PT. METISKA FARMA

Laras Wiranda¹, Mujiono Sadikin²

^{1,2} Jurusan Teknik Informatika, Fakultas Ilmu Komputer,
Universitas Mercu Buana
Jakarta, Indonesia

e-mail: 41515110040@student.mercubuana.ac.id¹, mujiono@mercubuana.ac.id²

Abstrak

Persaingan penjualan produk antar industri farmasi di Indonesia semakin ketat. Keadaan dan permintaan pasar juga menjadi semakin kompleks dan sulit diprediksi. Oleh karena itu, industri farmasi harus memiliki perencanaan strategis di bidang pemasaran, diantaranya melalui prediksi permintaan atau penjualan. Sejauh ini PT. Metiska Farma sudah menerapkan metode prediksi untuk kebutuhan rencana produksi. Namun, hasil dari metode peramalan yang telah dilakukan tidak akurat, selain kurang efektif karena dilakukan secara manual. Pada studi yang disajikan pada makalah, dilakukan uji coba prediksi berbasis teknik *Machine Learning* yaitu metode *Long Short Term Memory* (LSTM). Untuk menguji coba teknik yang diusulkan digunakan dataset produk "X" dengan parameter kinerja *Mean Absolute Percentage Error* (MAPE) dan *Root Mean Squared Error* (RMSE). Hasil penelitian melalui evaluasi kinerja model data training terhadap data testing, menunjukkan bahwa nilai LSTM dalam memprediksi penjualan sebesar 13,762,154.00 untuk RMSE dalam nilai rupiah dan MAPE sebesar 12%.

Kata kunci: Long Short Term Memory, Prediksi, Farmasi, Penjualan

Abstract

The competition in product sales between the pharmaceutical industry in Indonesia is getting tougher. Market conditions and demands are also increasingly complicated and unpredictable. Therefore, the pharmaceutical industry must have strategic planning in the marketing field, where the offer is available. Hitherto, PT. Metiska Farma has applied a prediction method for the needs of production plan. However, the results of applying such forecasting method are inaccurate, because, besides being less effective, this method is done manually. In the study presented in this paper, a prediction test based on Machine Learning techniques was conducted, which was the Long Short Term Memory (LSTM) method. To test the proposed technique, the product dataset "X" was used with performance parameters of Mean Absolute Percentage Error (MAPE) and Root Mean Squared Error (RMSE). The results of the study, through evaluating the model performance of data training on data testing, showed that the LSTM value in predicting sales was 13,762,154.00 for RMSE in rupiah values, and the MAPE was 12%.

Keywords : Long Short Term Memory, Prediction, Pharmacy, Sales

PENDAHULUAN

Pada saat ini hampir semua perusahaan yang bergerak di bidang industri dihadapkan pada suatu tantangan yaitu adanya tingkat persaingan yang semakin ketat. Hal ini mengharuskan

perusahaan untuk merencanakan semua parameter produksi dengan baik. Seperti kapasitas produksi agar dapat memenuhi permintaan pasar dengan tepat waktu dan dengan jumlah yang sesuai, sehingga

diharapkan keuntungan perusahaan akan meningkat [1].

Peramalan (*forecasting*) adalah seni dan ilmu untuk memperkirakan kejadian di masa depan. Hal ini dapat dilakukan dengan melibatkan pengambilan data historis dan memproyeksikannya ke masa mendatang. Dengan cara membentuk model matematis atau prediksi intuisi bersifat subyektif yang disesuaikan dengan pertimbangan yang baik [2]. Peramalan merupakan alat bantu yang sangat diperlukan bagi kebijakan perencanaan organisasi bisnis maupun pengambilan keputusan manajemen yang penting lainnya [3]. Salah satu manfaat peramalan penjualan adalah dapat memperkirakan penjualan secara akurat dari waktu ke waktu sehingga dapat dibuat rencana produksi yang sesuai dengan perkiraan penjualan [4].

Dengan adanya peramalan, maka perusahaan dapat mencapai tujuan perusahaan serta pengambilan keputusan dalam produksinya. Karena pentingnya peramalan, berbagai studi mengenai peramalan telah dilakukan. Terdapat beberapa studi terkait yang telah dilakukan oleh para peneliti diantaranya yaitu prediksi pergerakan saham [5], prediksi kunjungan wisatawan [6], prediksi arah indeks pasar saham harian [7], dan perbandingan metode klasifikasi untuk memprediksi potensi resiko [8].

Long Short Term Memory yang digunakan oleh Tingwei Gao, dkk [5] bertujuan untuk memprediksi pergerakan saham pada hari berikutnya. Data stok perdagangan dasar digunakan dalam pembuatan model prediksi. Pada studi ini peneliti membandingkan model LSTM dengan 3 model lainnya yaitu *moving average* (MA), *exponential moving average* (EMA), dan *support vector machine* (SVM). Kinerja dari keempat model tersebut kemudian dievaluasi menggunakan *Root Mean Square Error* (RMSE). Dari studi ini dihasilkan bahwa model MA memiliki nilai 40.9691, EMA 24.6726, SVM 21.8863, dan LSTM 20.4668.

Selanjutnya, penelitian mengenai prediksi kunjungan wisatawan di pulau

lombok oleh Ahmad Ashril Rizal dan Siti Soraya [6]. Penelitian ini mengkaji prediksi kunjungan wisatawan di pulau lombok dengan pendekatan *Recurrent Neural Network Long Short Term Memory* (RNN LSTM) menggunakan *multi time steps*. Kemudian kinerja model dievaluasi menggunakan *Root Mean Square Error* (RMSE). Hasil penelitian yang dilakukan untuk memprediksi kunjungan wisatawan dengan RNN LSTM menggunakan *multi time steps* mendapatkan hasil RMSE sebesar 6888.37 pada data training dan 14684.33 pada data testing.

Kemudian, pada penelitian yang dilakukan oleh QIU Mingyue, dkk adalah memprediksi arah indeks pasar saham harian [7]. Topik utama dari penelitian ini adalah kemampuan untuk memprediksi arah harga pada hari berikutnya dari indeks pasar saham Jepang. Pada studi ini, prediksi dilakukan menggunakan model *artificial neural network* (ANN) yang dioptimalkan menggunakan *genetic algorithms* (GA). Dalam menguji kinerja model eksperimen dilakukan dengan menerapkan dua tipe variabel input yaitu indikator input tipe satu dan indikator input tipe dua. Dari kedua variabel input tersebut, indikator input tipe dua memberikan kinerja yang lebih baik sebesar 86.39% untuk memprediksi arahnya.

Perbandingan metode klasifikasi pada data kandidat pelanggan untuk memprediksi potensi resiko. Studi yang dilakukan oleh Mujiono Sadikin & Fahri Alfiandi ini membandingkan metode data mining klasifikasi C.45 dengan *Naïve Bayes* pada penyedia kredit kendaraan untuk memprediksi calon pelanggan yang berpotensi menghasilkan lebih banyak keuntungan [8]. Kriteria pelanggan atau atribut yang digunakan untuk diteliti ada 5, yaitu gaji, usia, status perkawinan, cicilan dan kelayakan. Evaluasi kriteria dilakukan berdasarkan akurasi, daya ingat & presisi. Hasil evaluasi akurasi dan presisi yang dihasilkan oleh algoritma C.45 lebih baik dibandingkan dengan algoritma *Naïve Bayes*, yaitu 83.33% akurasi dan 89.16% presisi. Namun untuk daya ingat algoritma *Naïve Bayes* lebih baik dibandingkan

algoritma C.45, yaitu dengan nilai 83.75% untuk *Naïve Bayes* dan 82.22% untuk C.45.

PT. Metiska Farma adalah perusahaan yang bergerak di bidang industri farmasi. Untuk memenuhi kebutuhan pasar, industri farmasi perlu melakukan perencanaan sebelum melakukan tahap produksi. Perencanaan produksi biasanya dilakukan berdasarkan prediksi atau peramalan. Prediksi penjualan sangat dibutuhkan untuk meningkatkan nilai produk baru dan juga untuk meningkatkan jumlah produksi [9]. Perusahaan ini telah melakukan prediksi penjualan namun hasilnya kurang akurat. Semakin banyak permintaan pasar, semakin sulit untuk melakukan prediksi dengan cara manual. Untuk mengatasi permasalahan kesulitan peramalan secara manual tersebut, pada penelitian ini dilakukan eksperimen peramalan berbasis *Machine Learning* menggunakan teknik *Long Short Term Memory*.

Metode yang dapat diterapkan adalah *Long Short Term Memory* (LSTM). Tujuan utama dari LSTM pada kasus peramalan (*forecasting*) adalah membuat prediksi yang akurat terhadap suatu variabel. Peramalan terbaik didasarkan pada tingkat kesalahan prediksi, di mana semakin kecil tingkat kesalahan yang dihasilkan, semakin tepat sebuah metode dalam memprediksi [1]. Perhitungan tingkat kesalahan yang digunakan pada studi ini adalah *Root Mean Square Error* (RMSE) dan *Mean Absolute Percent Error* (MAPE).

Pada penelitian ini digunakan data penjualan antara tahun 2017 sampai dengan 2019. Data penjualan di PT. Metiska Farma memiliki atribut waktu (tanggal penjualan) dan nilai (value penjualan harian yang didapat dalam bentuk rupiah) sehingga termasuk ke dalam

METODE

A. Dataset

Dataset diperoleh dari data penjualan obat harian PT. Metiska Farma. Bentuk dataset yang digunakan berupa *time series*. Data penjualan obat "X" per hari dalam kurun waktu 3 tahun terakhir, yaitu penjualan tahun 2017 – 2019

data *time series* yang tergolong sebagai data *sequence*. Data *time series* merupakan suatu rangkaian pengamatan berdasarkan urutan waktu dari karakteristik kuantitatif dari satu atau kumpulan kejadian yang diambil dalam periode waktu tertentu.

Long Short Term Memory (LSTM) merupakan salah satu pengembangan *neural network* yang dapat digunakan untuk pemodelan data *time series* [10]. LSTM mampu mengatasi ketergantungan jangka panjang (*long term dependencies*) pada masukannya. Sebuah penelitian *A New Method for Semantic Consistency Verification of Aviation Radiotelephony Communication Based on LSTM-RNN* mengatakan bahwa LSTM berhasil diterapkan pada berbagai tugas sekuensial dan bahasa pemodelan [11]. Sebuah *cell* dalam LSTM menyimpan sebuah nilai atau keadaan (*cell state*), baik untuk periode waktu yang panjang atau singkat. LSTM mempunyai *memory block* yang akan menentukan nilai mana yang akan dipilih sebagai keluaran yang relevan terhadap masukan yang diberikan. Hal ini adalah keunggulan yang dimiliki oleh LSTM.

Pada penelitian ini dilakukan 3 tahap utama yaitu: 1) *Preprocessing Data*; 2) Pembuatan model melalui proses training *LSTM Network*; 3) Melakukan uji terhadap data testing. Hasil akhir penelitian ini berupa prediksi penjualan yang akan dijadikan sebagai acuan dalam perencanaan produksi perusahaan. Setelah mendapatkan prediksi dari skenario terbaik, kinerja LSTM dievaluasi menggunakan RMSE dan MAPE. Hasil penelitian dengan kinerja terbaik ditunjukkan dari nilai kesalahan terkecil yang dihasilkan oleh RMSE yang mencapai angka 13,762,154.00 dan MAPE mencapai angka 12%.

dikumpulkan dan kemudian dikonversi menjadi file csv (*comma separated values*). Data yang terkumpul sebanyak 603 row data. Setiap instant data mengandung dua atribut, yaitu Tanggal dan Nilai. Tanggal adalah tanggal penjualan dan nilai adalah value pendapatan perhari dari penjualan obat tersebut dalam bentuk rupiah.

Penjelasan atribut dan beberapa contoh instant data disajikan pada Tabel 1 dan Tabel 2.

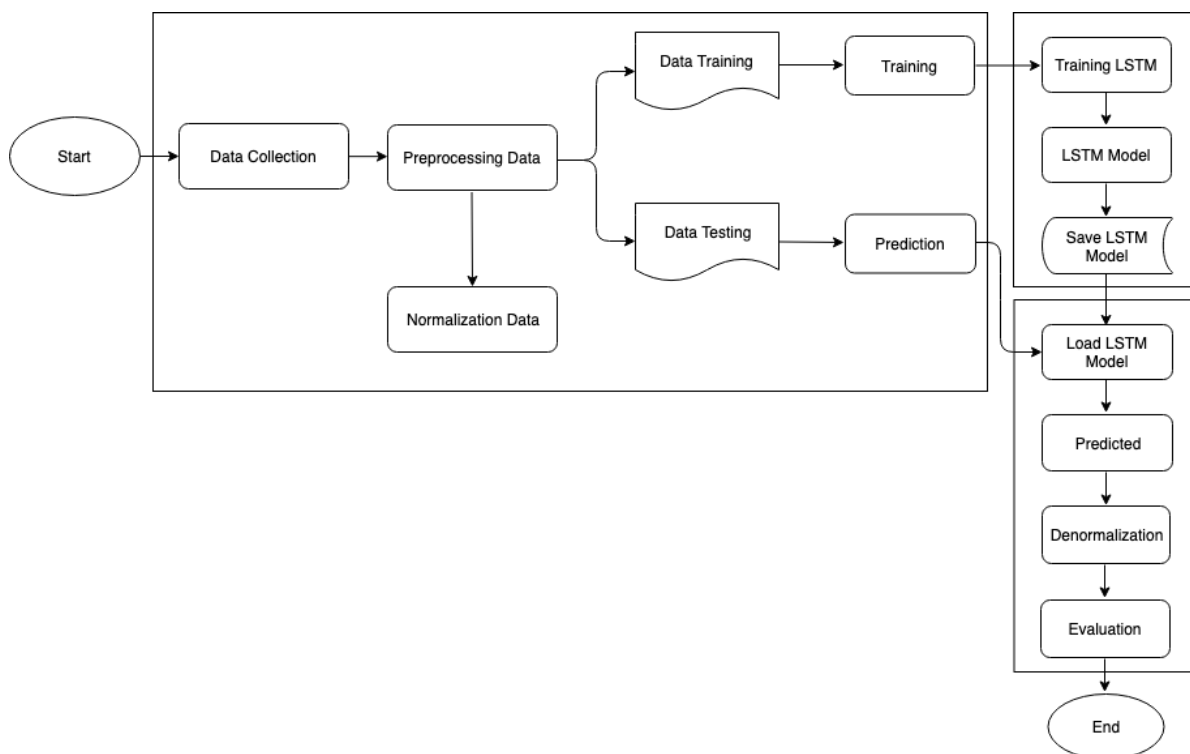
Tabel 1. Atribut Dataset

No	Atribut	Nilai Atribut
1	Tanggal	2017-04-01, 2017-04-03, dll
2	Nilai Penjualan (Rupiah)	5,880,000; 11,585,000; dll

Table 2. Contoh Nilai Atribut Dataset

No	Tanggal	Nilai
1	2017-04-01	5,880,000
2	2017-04-03	11,585,000
3	2017-04-04	41,090,000
4	2017-04-05	40,320,000
5	2017-04-06	18,130,000

B. Tahapan Eksperimen



Gambar 1. Tahapan Eksperimen

Tahapan aktivitas dalam penelitian ini berturut – turut: penyiapan data, pembuatan model, dan evaluasi model. Tahapan penyiapan data terdiri dari pengumpulan data, *preprocessing*, representasi data, dan pemilahan data (*dataset splitting*). Tahapan rinci diilustrasikan seperti pada Gambar 1. *Preprocessing data* terdiri dari data *cleansing* dan normalisasi dataset. Setelah tahap *preprocessing data* selesai dilakukan kemudian dataset dibagi menjadi dua, dataset training dan dataset testing. Tahap selanjutnya dalam penelitian ini untuk mencapai hasil prediksi proses membangun sistem dibagi menjadi dua yaitu proses training dan proses prediksi. Karena saat menjalankan proses pembuatan model memakan waktu yang cukup lama, maka proses training dilakukan secara terpisah dengan proses prediksi.

Tahap eksperimen model dimulai dengan pembuatan model dan training *LSTM Network*. Hasil training berupa model LSTM yang berupa file HDF5 atau .h5 [12]. Model yang diperoleh selanjutnya digunakan pada proses prediksi dengan memuat file model. Tahap akhir eksperimen berupa proses denormalisasi data hasil testing untuk mendapatkan nilai hasil prediksi dan nilai evaluasi dari hasil kinerja model.

Manfaat dari proses training dan prediksi dilakukan secara terpisah adalah ketika menjalankan proses prediksi jika tidak ada data baru. Tidak perlu melakukan pemodelan data training kembali melainkan langsung memuat dari file .h5 tersebut. Hal itu akan mempercepat proses prediksi karena tanpa harus melakukan training kembali terhadap data yang sama.

C. Input Dataset

Dataset yang digunakan pada penelitian ini adalah data penjualan antara tahun 2017 sampai dengan 2019. Dataset yang dikumpulkan kemudian dipilah menjadi data training dan data testing. Skenario penggunaan dataset untuk eksperimen disiapkan berdasarkan

komposisi data testing dan data training dalam prosentase. Skenario uji coba tersebut disajikan pada Tabel 3. Setelah seluruh dataset tersebut dibagi sesuai komposisi yang dibutuhkan, masing – masing data training dan data testing dikonversi menjadi file csv (*comma separated values*).

Table 3. Komposisi Dataset

No	Data Training	Data Testing
1	70%	30%
2	80%	20%
3	90%	10%

D. Preprocessing Data

Proses *Preprocessing Data* pada studi ini dengan melakukan normalisasi pada dataset menggunakan teknik *min-max scaler* dari *sklearn* [13]. Caranya dengan merubah nilai real atau nilai aktual menjadi nilai dengan range interval. Nilai range interval dalam penelitian ini juga dibagi menjadi dua uji coba, yaitu [0,1] dan [1,1] untuk mendapatkan nilai prediksi yang terbaik. Dibawah ini adalah rumus untuk normalisasi.

$$x' = \frac{x - x_{min}}{x_{max} - x_{min}} \quad (1)$$

Keterangan:

x' = Nilai hasil normalisasi

x = Nilai data aktual yang akan dinormalisasi

x_{min} = Nilai minimum dari data aktual


x_{max} = Nilai maksimum dari data aktual

E. Long Short Term Memory Network

Long Short Term Memory (LSTM) disebutkan untuk pertama kali pada tahun 1997 dijelaskan oleh Hochreiter dan Schmidhuber [14]. LSTM disebut juga sebagai jaringan saraf dengan arsitektur yang mudah beradaptasi, sehingga

bentuknya dapat disesuaikan, tergantung pada aplikasinya. *Long Short Term Memory* merupakan turunan dari metode RNN (*Recurrent Neural Network*). *Recurrent Neural Network* merupakan jaringan saraf berulang yang didesain khusus untuk *handle* data berurutan (*sequence data*). Namun RNN mempunyai masalah *vanishing* dan *exploding gradient* yaitu apabila terjadi perubahan pada jangkauan nilai dari satu lapisan menuju lapisan


berikutnya pada sebuah arsitektur. LSTM dibangun dan dirancang untuk mengatasi masalah gradien menghilang dari RNN ketika berhadapan dengan *vanishing* dan *exploding gradient* tersebut. Arsitektur LSTM terdiri dari lapisan input, lapisan output, dan lapisan tersembunyi yang disajikan pada Gambar 2.



Gambar 2. Arsitektur *Long Short Term Memory* (LSTM)

Lapisan tersembunyi terdiri dari sel memori, satu sel memori memiliki tiga gate yaitu *input gate*, *forget gate*, *output gate* [15]. *Input gate* berfungsi mengontrol berapa banyak informasi yang harus disimpan dalam keadaan sel. Ini mencegah sel dari menyimpan data yang tidak perlu. *Forget gate* berfungsi mengontrol sejauh mana nilai tetap di dalam sel memori. *Output Gate* berfungsi untuk memutuskan berapa banyak konten atau nilai dalam sel memori, digunakan untuk menghitung *output* [16].

Gambar 3 menyajikan isi dari lapisan tersembunyi LSTM yaitu sel memori. Sebuah sel memori di LSTM menyimpan sebuah nilai atau keadaan (*cell state*), baik untuk periode waktu yang panjang atau singkat. Penjelasan untuk gerbang – gerbang yang ada pada satu sel memori *Long Short Term Memory* (LSTM) adalah sebagai berikut:



Gambar 3. Sell Memory LSTM

1. *Input Gate* (i_t)

Input gate berperan mengambil *output* sebelumnya dan *input* baru serta melewati mereka melalui lapisan *sigmoid*. Gate ini mengembalikan nilai 0 atau 1. Rumus dari i_t adalah:

$$i_t = \sigma(W_i S_{t-1} + W_i X_t) \quad (2)$$

Dengan,

W_i = Bobot dari *Input Gate*.

S_{t-1} = *State* sebelumnya atau *state* pada waktu $t-1$.

X_t = Input pada waktu t .

σ = Fungsi aktivasi *sigmoid*.

Nilai gerbang *input* dikalikan dengan *output* dari lapisan kandidat (\tilde{C}). Rumus dari (\tilde{C}) adalah:

$$\tilde{C} = \tanh(W_c S_{t-1} + W_c X_t) \quad (3)$$

$$c_t = (i_t * \tilde{C} + f_t * c_{t-1}) \quad (4)$$

Dengan,

\tilde{C} = *Intermediate cell state*.

W_c = Bobot dari *cell state*.

S_{t-1} = *State* sebelumnya atau *state* pada waktu $t - 1$.

X_t = *Input* pada waktu t .

State sebelumnya dikalikan dengan *forget gate* dan kemudian ditambahkan ke fungsi kandidat baru yang diizinkan oleh *output gate*.

2. Forget Gate (f_t)

Forget gate adalah lapisan *sigmoid* yang mengambil *output* pada waktu $t - 1$ dan *input* pada waktu t dan menggabungkannya serta menerapkan fungsi aktivasi *sigmoid*. Karena *sigmoid*, *output* dari *gate* ini adalah 0 atau 1. Jika $f_t = 0$ maka keadaan (*state*) sebelumnya akan dilupakan, sementara jika $f_t = 1$ *state* sebelumnya tidak berubah. Rumus dari f_t adalah:

$$f_t = \sigma(W_f S_{t-1} + W_f X_t) \quad (5)$$

Dengan,

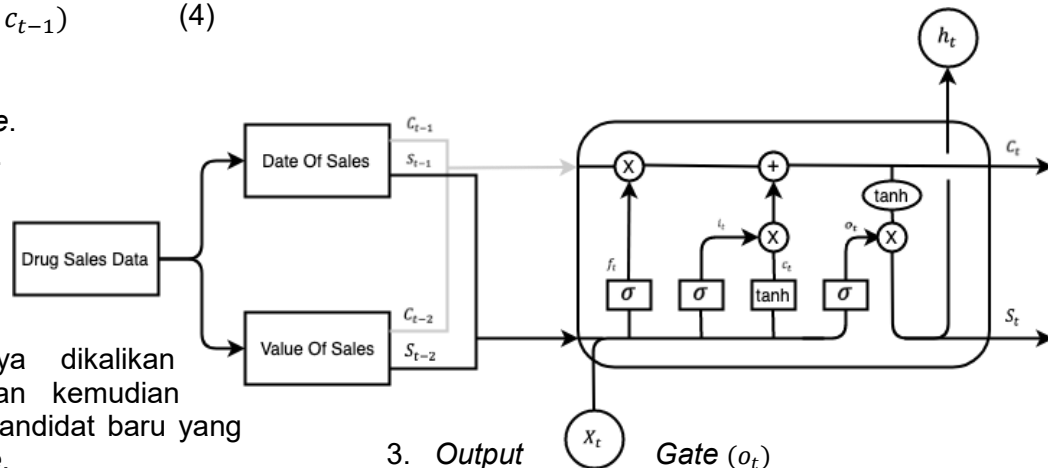
W_f = Bobot dari *forget gate*.

S_{t-1} = *State* sebelumnya atau *state* pada waktu $t - 1$.

X_t = *Input* pada waktu t .

σ = Fungsi aktivasi *sigmoid*.

Lapisan ini menerapkan tangen hiperbolik ke campuran *input* dan *output* sebelumnya. Mengembalikan vektor kandidat yang akan ditambahkan ke *state*. *State* diperbarui dengan rumus:



3. Output Gate (o_t)

Output gate mengontrol seberapa banyak *state* yang lewat ke *output* dan bekerja dengan cara yang sama dengan *gate* lainnya. Dan terakhir menghasilkan *cell state* yang baru (h_t). Rumus dari o_t dan h_t adalah:

$$o_t = \sigma(W_o S_{t-1} + W_o X_t) \quad (6)$$

$$h_t = o_t * \tanh(c_t) \quad (7)$$

Dengan,

W_o = Bobot dari *output gate*.

S_{t-1} = *State* sebelumnya atau *state* pada waktu $t - 1$.

X_t = *Input* pada waktu t .

σ = Fungsi aktivasi *sigmoid*.

Akurasi prediksi yang dihasilkan diperoleh dari data yang sudah dilatih dan kunci keberhasilan kedua hal tersebut adalah dari jumlah lapisan tersembunyi [17]. Atribut yang digunakan pada penelitian ini ada dua yaitu tanggal penjualan dan nilai atau value pendapatan perhari dari penjualan obat PT. Metiska Farma. Arsitektur *Long Short Term Memory* (LSTM) untuk memprediksi penjualan obat PT. Metiska Farma disajikan melalui Gambar 4

Gambar 4. Arsitektur LSTM untuk Prediksi Penjualan PT. Metiska Farma

F. Denormalisasi

Setelah mendapatkan hasil prediksi dari proses prediksi, maka sebelum menghitung akurasi hasil prediksi harus dilakukan denormalisasi yaitu data diubah menjadi nilai *real* kembali [18]. Karena data hasil prediksi masih berupa data berbentuk *range interval* yang dilakukan pada normalisasi data. Tujuan denormalisasi adalah agar *output* mudah dibaca dan mudah dimengerti. Dibawah ini adalah rumus untuk denormalisasi.

$$d = d'(max - min) + min \quad (8)$$

Dengan,

d = Nilai hasil denormalisasi

d' = Nilai data normalisasi

max = Nilai maksimum dari data aktual

min = Nilai minimum dari data aktual

G. Evaluasi

Untuk mengevaluasi kinerja model pada penelitian ini digunakan *Root Mean Square Error* (RMSE) dan *Mean Absolute Percentage Error* (MAPE). *Root Mean Square Error* (RMSE) yaitu metode alternatif untuk mengevaluasi teknik peramalan yang digunakan untuk mengukur tingkat akurasi hasil perkiraan suatu model [19]. Nilai yang dihasilkan RMSE merupakan nilai rata – rata kuadrat dari jumlah kesalahan pada model prediksi. *Root Mean Square Error* (RMSE) adalah teknik yang mudah diimplementasikan dan telah sering digunakan dalam berbagai studi yang berkaitan dengan peramalan [20].

Mean Absolute Percentage Error (MAPE) merupakan rata – rata *diferensiasi absolut* antara nilai peramalan dan aktual, yang dinyatakan sebagai persentase nilai aktual [3]. MAPE digunakan untuk menghitung persentase kesalahan antara nilai aktual dan nilai prediksi. Ada berbagai

ukuran akurasi dalam peramalan, di antaranya adalah MAPE dan RMSE yang diungkapkan oleh rumus berikut [21].

a. *Root Mean Square Error* (RMSE)

$$\sqrt{\frac{1}{n} \sum_{i=1}^n (\tilde{y}_i - y_i)^2} \quad (9)$$

Keterangan:

\tilde{y}_i = Nilai hasil peramalan

y_i = Nilai aktual / Nilai sebenarnya

n = Jumlah data

b. *Mean Absolute Percentage Error* (MAPE)

$$100 \times \frac{1}{n} \sum_{i=1}^n \left| \frac{\tilde{y}_i - y_i}{y_i} \right| \quad (10)$$

Keterangan:

\tilde{y}_i = Nilai hasil peramalan

y_i = Nilai aktual / Nilai sebenarnya

n = Jumlah data

HASIL DAN PEMBAHASAN

Percobaan yang memberikan nilai kinerja tertinggi untuk setiap metode digunakan sebagai model untuk menemukan metode terbaik dengan menguji ulang pada pengujian data yang disediakan. Sebelum melakukan pengujian terhadap metode penelitian ini, penggunaan parameter perlu dilakukan. Karena dalam menganalisa dampak dari parameter akan mempengaruhi hasil akurasi. Beberapa

parameter uji yang digunakan adalah sebagai berikut:

1. Komposisi Dataset – (P1)
2. Nilai *Range Interval* – (P2)

Dari parameter yang disediakan dapat dibuat skenario untuk beberapa pengujian ulang dalam penelitian ini. Tabel

4 menyajikan skenario eksperimen dari parameter yang disediakan. Tabel 5 menunjukkan hasil pembagian dalam pembuatan skenario eksperimen untuk menemukan metode terbaik dalam pengujian yang dilakukan dalam penelitian ini.

Tabel 4. Skenario Eksperimen

	1	2	3
P1	70/30	80/20	90/10
P2	[-1,1]	[0,1]	

Tabel 5. Jumlah Eksperimen
Eksperimen Parameter

1	= P1.1, P2.1
2	= P1.1, P2.2
3	= P1.2, P2.1
4	= P1.2, P2.2
5	= P1.3, P2.1
6	= P1.3, P2.2

Pada penelitian ini, membangun model prediksi LSTM berdasarkan *framework deep learning* yaitu *Keras* yang merupakan *platform Python*. Percobaan dilakukan beberapa kali berdasarkan jumlah eksperimen yang telah ditetapkan dalam Tabel 5. Tabel 6 menyajikan hasil penelitian dari beberapa tahap yang sudah dilakukan sebelumnya.

Peramalan terbaik didasarkan pada tingkat kesalahan prediksi, di mana semakin kecil tingkat kesalahan yang

dihasilkan, semakin tepat sebuah metode dalam memprediksi. Hasil eksperimen dari studi ini diperoleh satu prediksi terbaik yang mempunyai nilai evaluasi model terendah menggunakan RMSE dan MAPE setelah denormalisasi secara berturut – turut yaitu 13,762,154.00 dan 12%. Nilai tersebut adalah jumlah rata – rata total dari seluruh hasil test setiap instant data sesuai dengan komposisi yang telah diskenariokan.


Tabel 6. Hasil Nilai RMSE dari Seluruh Eksperimen

Eksperimen	Parameter	RMSE	MAPE
1	= P1.1, P2.1	51,188,750.00	82%
2	= P1.1, P2.2	24,203,660.00	74%
3	= P1.2, P2.1	25,265,271.00	45%

4	= P1.2, P2.2	27,631,289.00	54%
5	= P1.3, P2.1	13,762,154.00	12%
6	= P1.3, P2.2	15,619,567.00	31%

Hasil dari eksperimen kelima memberikan nilai RMSE yang paling rendah, yaitu sebesar 13,762,154.00 dan MAPE sebesar 12%. Dengan begitu sudah dapat diperoleh perbandingan nilai hasil prediksi dengan nilai aktual dari eksperimen

tersebut. Melalui plot dan tabel yang disajikan pada Gambar 5 dan Tabel 7 dapat dilihat perbandingan nilai hasil prediksi dengan nilai aktual dari eksperimen kelima yang telah dilakukan



Gambar 5. Plot Hasil Eksperimen Kelima

Tabel 7 menunjukkan hasil eksperimen yang dilakukan pada studi ini dengan menerapkan model LSTM untuk memprediksi pendapatan penjualan PT. Metiska Farma pada hari yang akan datang. Kinerja model dievaluasi menggunakan *Root Mean Square Error* (RMSE) dan *Mean Absolute Percentage Error* (MAPE). Dari hasil diketahui bahwa

eksperimen kelima memberikan hasil yang paling baik. Hal ini ditunjukkan oleh nilai evaluasi atau rata – rata kesalahan yang dihasilkan lebih kecil dibandingkan dengan nilai rata – rata kesalahan pada eksperimen lainnya.

Hasil evaluasi kinerja model menggunakan MAPE pada eksperimen kelima menunjukkan bahwa tingkat

persentase rata – rata kesalahan model antara nilai prediksi dengan nilai aktual perhari terkecil adalah 12%. Perlu diketahui bahwa nilai persentase *error* yang tinggi disebabkan oleh penjualan yang terjadi di akhir bulan, karena terkadang pada akhir bulan PT. Metiska Farma memberikan diskon saat

menjualkan produknya. Maka selisih yang dihasilkan lebih tinggi pada hari – hari tertentu seperti ditunjukkan pada prediksi hasil eksperimen atau yang disebut juga dengan data *outlier*.

Tabel 7. Hasil Nilai Prediksi dan Nilai Aktual Eksperimen Kelima

<i>Day</i>	<i>Predicted</i>	<i>Expected</i>	MAPE
1	11,401,761.07	12,705,000.00	10%
2	45,547,249.53	49,595,000.00	8%
3	24,497,844.70	27,685,000.00	12%
4	29,408,351.32	33,110,000.00	11%
5	21,020,859.60	24,395,000.00	14%
...
11	456,838,651.49	489,195,000.00	7%
12	8,687,088.69	11,165,000.00	22%
13	10,362,349.13	10,010,000.00	4%
14	31,670,533.23	32,025,000.00	1%
15	201,475,229.81	212,730,000.00	5%
...
21	57,434,408.86	59,780,000.00	4%
22	26,033,044.91	26,810,000.00	3%
23	46,367,671.00	48,685,000.00	5%
24	10,379,442.74	10,745,000.00	3%
25	196,269,260.67	208,950,000.00	6%
...
31	20,753,156.84	21,000,000.00	1%
32	31,283,508.79	32,410,000.00	3%
33	203,593,754.30	216,265,000.00	6%

34	1,145,212,114.03	1,221,990,000.00	6%
35	174,632,649.80	185,255,000.00	6%

KESIMPULAN

Dalam studi ini, *Long Short Term Memory* diimplementasikan pada dataset penjualan obat "X" di PT. Metiska Farma untuk memprediksi penjualan di masa depan untuk perusahaan tersebut. Berdasarkan dua parameter percobaan hasil skenario, percobaan kelima mencapai kinerja yang lebih baik. Hasil penelitian ini menunjukkan bahwa metode terbaik penggunaan LSTM dengan komposisi data latih 90% dan data uji 10%, *range interval* [-1,1] dan *epoch* sebanyak 1500. Metode tersebut mendapatkan hasil perhitungan RMSE dalam bentuk rupiah sebesar 13,762,154.00 dan hasil persentase rata – rata kesalahan model antara nilai prediksi dengan nilai aktual perhari terkecil dengan menggunakan MAPE adalah 12%. Dalam studi selanjutnya, kami akan mengeksplorasi beberapa peluang untuk menerapkan teknik yang lain dalam domain ini. Sehingga, kami dapat membangun model LSTM dengan menambahkan fitur baru dalam *memory cell* dan proses optimasi baru yang digunakan.

REFERENSI

- [1] M. Jurusan, T. Industri, F. T. Pertanian, D. Jurusan, T. Industri, and F. T. Pertanian, "ANALISIS PERAMALAN PENJUALAN PRODUK KECAP PADA PERUSAHAAN KECAP MANALAGI DENPASAR BALI Ni Putu Lisna Padma Yanti 1, I.A Mahatma Tuningrat 2, A.A.P. Agung Suryawan Wiranatha 2 1," *J. REKAYASA DAN Manaj. AGROINDUSTRI*, vol. 4, no. 1, pp. 72–81, 2016.
- [2] M. Savira, N. N. K. Moeliono, and S. Sos, "ANALISIS PERAMALAN PENJUALAN OBAT GENERIK BERLOGO (OGB) PADA PT. INDONESIA FARMA," *eProceedings Manag.*, pp. 1–12, 2015.
- [3] S. Riyadi, "Aplikasi Peramalan Penjualan Obat Menggunakan Metode Pemulusan (Studi Kasus: Instalasi Farmasi Rsud Dr Murjani)," *Stmik Amikom*, no. 1, pp. 1–6, 2015.
- [4] F. R. Hariri, "Metode Least Square Untuk Prediksi Penjualan Sari Kedelai Rosi," *Simetris J. Tek. Mesin, Elektro dan Ilmu Komput.*, vol. 7, no. 2, p. 731, 2016.
- [5] T. Gao, Y. Chai, and Y. Liu, "Applying long short term momory neural networks for predicting stock closing price," *Proc. IEEE Int. Conf. Softw. Eng. Serv. Sci. ICSESS*, vol. 2017-Novem, pp. 575–578, 2018.
- [6] A. A. Rizal and S. Soraya, "Multi Time Steps Prediction dengan Recurrent Neural Network Long Short Term Memory," *MATRIK J. Manajemen, Tek. Inform. dan Rekayasa Komput.*, vol. 18, no. 1, pp. 115–124, 2018.
- [7] Q. Mingyue, L. Cheng, and S. Yu, "Application of the Artificial Neural Network in Predicting the Direction of Stock Market Index," *Proc. - 2016 10th Int. Conf. Complex, Intelligent, Softw. Intensive Syst. CISIS 2016*, pp. 219–223, 2016.
- [8] M. Sadikin and F. Alfiandi, "Comparative study of classification method on customer candidate data to predict its potential risk," *Int. J. Electr. Comput. Eng.*, vol. 8, no. 6, pp. 4763–4771, 2018.
- [9] D. R. Indah, "Sistem Forecasting Perencanaan Produksi dengan Metode Single Eksponensial Smoothing pada Keripik Singkong Srikandi Di Kota Langsa," vol. 2, no. 1, pp. 10–18, 2018.
- [10] D. I. Komputer, F. Matematika, D. A. N. Ilmu, and P. Alam, "Prediksi temporal untuk kemunculan titik panas di kabupaten rokan hilir riau

- menggunakan long short term memory rnn hafshah luthfiah,” 2018.
- [11] Y. Lu, Y. Shi, G. Jia, and J. Yang, “A new method for semantic consistency verification of aviation radiotelephony communication based on LSTM-RNN,” *Int. Conf. Digit. Signal Process. DSP*, pp. 422–426, 2017.
- [12] J. Zhao, Y. Wang, and H. Zhang, “Automated batch processing of mass remote sensing and geospatial data to meet the needs of end users,” *Int. Geosci. Remote Sens. Symp.*, pp. 3464–3467, 2011.
- [13] N. P. Sakinah, I. Cholissodin, and A. W. Widodo, “Prediksi Jumlah Permintaan Koran Menggunakan Metode Jaringan Syaraf Tiruan Backpropagation,” *J. Pengemb. Teknol. Inf. dan Ilmu Komput. Univ. Brawijaya*, vol. 2, no. 7, pp. 2612–2618, 2017.
- [14] L. Skovajsová, “Long Short-Term Memory Description and its Application in Text Processing.”
- [15] R. Vinayakumar, K. P. Soman, and P. Poornachandran, “Long short-term memory based operation log anomaly detection,” *2017 Int. Conf. Adv. Comput. Commun. Informatics, ICACCI 2017*, vol. 2017-Janua, pp. 236–242, 2017.
- [16] G. Mathisen, “Forecasting Multivariate Time Series Data Using Neural Networks Sigurd Øyen,” no. June, 2018.
- [17] X. Qu, X. Kang, Z. Chao, J. Shuai, and X. Ma, “Short-term prediction of wind power based on deep Long Short-Term Memory,” *Asia-Pacific Power Energy Eng. Conf. APPEEC*, vol. 2016-Decem, pp. 1148–1152, 2016.
- [18] N. M. Ashar, I. Cholissodin, and C. Dewi, “Penerapan Metode Extreme Learning Machine (ELM) Untuk Memprediksi Jumlah Produksi Pipa Yang Layak (Studi Kasus Pada PT . KHI Pipe Industries),” *J. Pengemb. Teknol. Inf. dan Ilmu Komput. Univ. Brawijaya*, vol. 2, no. 11, pp. 4621–4628, 2018.
- [19] Y. Abdillah and Suharjito, “Failure prediction of e-banking application system using Adaptive Neuro Fuzzy Inference System (ANFIS),” *Int. J. Electr. Comput. Eng.*, vol. 9, no. 1, pp. 667–675, 2019.
- [20] N. R. Sari, W. F. Mahmudy, A. P. Wibawa, and E. Sonalitha, “Enabling external factors for inflation rate forecasting using fuzzy neural system,” *Int. J. Electr. Comput. Eng.*, vol. 7, no. 5, pp. 2746–2756, 2017.
- [21] H. Kusdarwati and S. Handoyo, “System for prediction of non stationary time series based on the wavelet radial bases function neural network model,” *Int. J. Electr. Comput. Eng.*, vol. 8, no. 4, pp. 2327–2337, 2018.